数据集成第三次作业

小组成员：黄相淇、王子悦、张刘洋、周辰熙
选择主题：主题一：客户星级和信用等级评估，利用机器学习的方法对用户**星级**和**信用等级**进行评估

1. 数据准备

在第二次作业的基础上，本次作业我们选用了 **DBeaver** 工具将位于服务器上的clickhouse中的数据下载至本地，以便于后续读取、处理

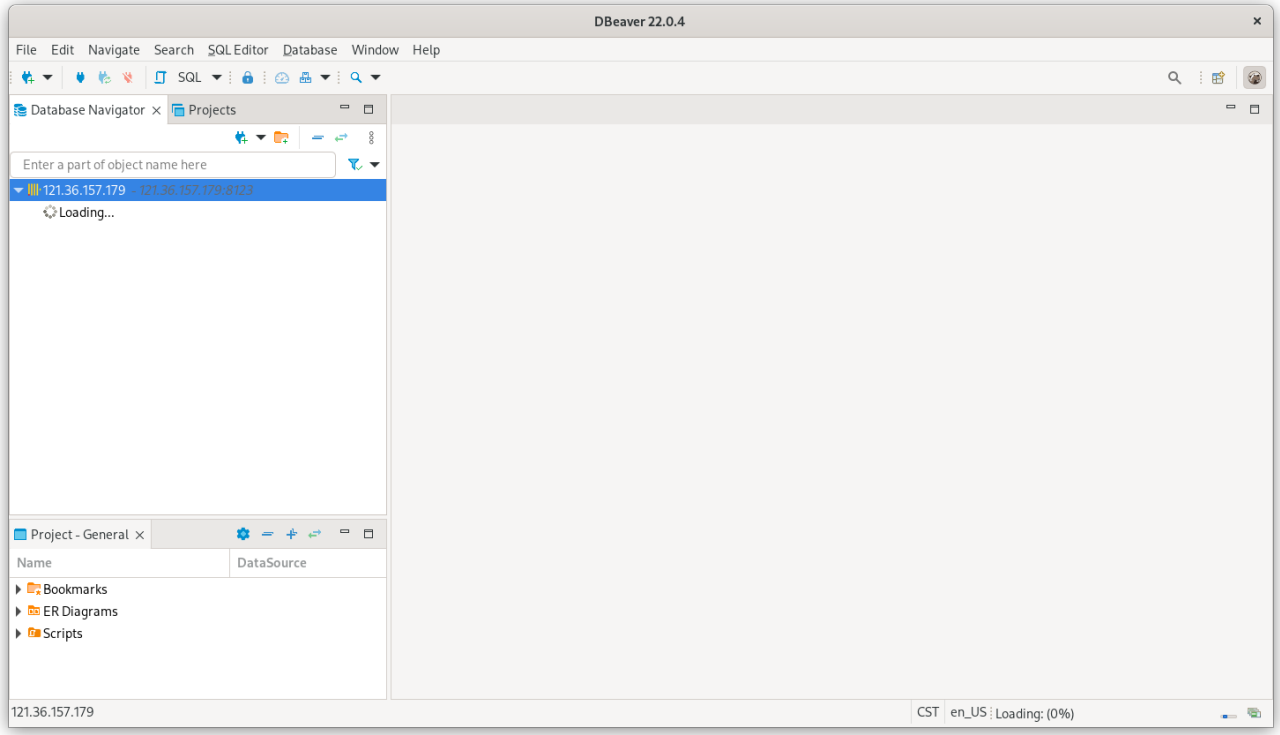

数据以csv文件格式进行存储

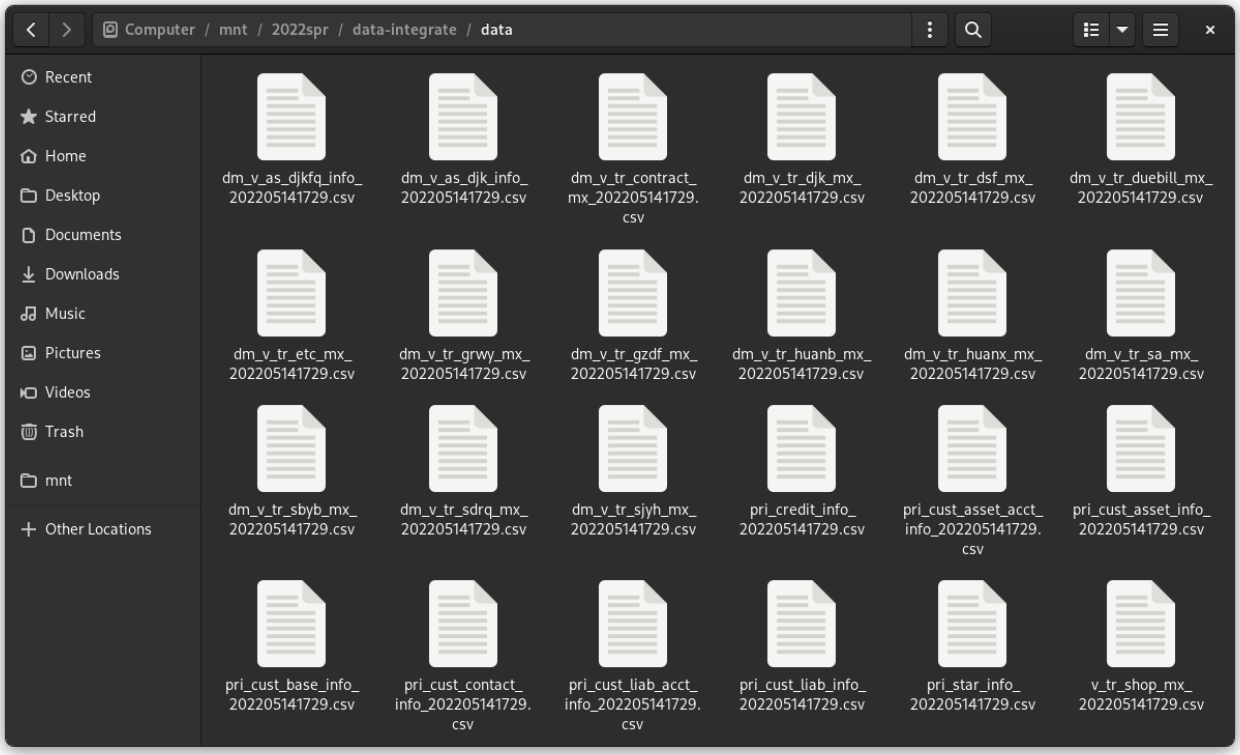

2.数据读取和预处理

2.1 读取

首先使用**pandas**读取csv文件

> *e.g. pri_cust_asset_info表*

```
cust_asset = pandas.read_csv(
        "/mnt/2022spr/data-integrate/data/pri_cust_asset_info_202205141729.csv",
        usecols=[
            "uid",          # 证件号码，用作连接各个pandas dataframe使用
            "all_bal",      # 总余额
            "avg_mth",      # 月日均
            "avg_year",     # 年日均
            "sa_bal",       # 活期余额
            "td_bal",       # 定期余额
            "fin_bal",      # 理财余额
            "sa_crd_bal",   # 卡活期余额
            "sa_td_bal"     # 定活两便
        ]
    )
```

> *由于表中部分数据列的值均相同(e.g. etl日期、某些列均为0)，因此我们只读取部分行*
>
> *e.g. pri_star_info表*
>
> ```
> pri_star_table = pandas.read_csv (
>         "/mnt/2022spr/data-integrate/data/pri_star_info_202205141729.csv"
>     )
> ```
>
> *该表只有两列，分别为uid和star_level，标明了数据的标签*

2.2 表连接

pandas也提供了类似于数据库的join操作

> *e.g. 连接上面读取的两个表*
>
> ```
> res = pandas.merge(pri_star_table, cust_asset, how='left', on='uid')
> res = res[(res['star_level']!=-1)]
> res = res[(res['all_bal'].notnull())]
> ```
>
> `pandas.merge`*操作将两个pandas dataframe进行连接，上面的代码标明是left join, 以uid进行连接。我们先进行模型训练，因此将合并后标签为-1的行过滤掉；同时由于连接，也有可能出现部分行存在空值的情况，也将其过滤掉*

2.3 数据预处理

上述操作得到的依旧是一个pandas dataframe,无法直接进行模型训练，因此需要将其转为可以使用模型训练的数据结构 (e.g. numpy.ndarray / torch.tensor)，同时进行数据预处理 (e.g. 中心化、归一化)

> ```
>     train_mapper = DataFrameMapper ([
>         (['all_bal'], sklearn.preprocessing.StandardScaler()),
>         (['avg_mth'], sklearn.preprocessing.StandardScaler()),
>         (['avg_year'], sklearn.preprocessing.StandardScaler()),
> ```

```
        (['sa_bal'], sklearn.preprocessing.StandardScaler()),
        (['td_bal'], sklearn.preprocessing.StandardScaler()),
        (['fin_bal'],
sklearn.preprocessing.StandardScaler()),
        (['sa_crd_bal'],
sklearn.preprocessing.StandardScaler()),
        (['acct_bal'],
sklearn.preprocessing.StandardScaler()),
    ])

    X = np.round (train_mapper.fit_transform(res.copy()), 2)
# 得到向量化数据

    labels_mapper = DataFrameMapper([
        (['star_level'], None)
    ])

    Y = np.round (labels_mapper.fit_transform(res.copy()))
# 得到数据标签
```

上述代码定义了一个mapper,将data frame的每一列数据进行映射，`sklearn.preprocessing.StandardScaler()`将数据进行标准化，以便于模型训练。之后np.round将其转化为可供训练使用的numpy数组，保留两位小数

2.4 使用机器学习模型进行训练

首先将数据划分为训练集和测试集

```
X_train, X_test, Y_train, Y_test = train_test_split (
        X, Y, test_size=0.2
    )   # 以 8 : 2 的比例划分训练集和测试集
```

2.4.1 决策树

混淆矩阵:

```
[[17002   982    21     2     0     0     0     0     0]
 [  853  6991   246     4     2     0     0     0     0]
 [   31   365  6708   354    24     0     0     0     0]
 [   10     7   346  1598   247    17     1     0     0]
 [    6     2    18   272  1365   121     0     0     0]
 [    4     0     1     5    84   774     3     0     0]
 [    0     0     0     0     1     1    30     0     0]
 [    0     0     0     0     0     0     0     4     0]
 [    0     0     0     0     0     0     0     0     2]]
```

准确度：0.8939

2.4.2 支持向量机

混淆矩阵:

```
[[17151   606    52     2     2     1     0     0     0]
 [ 2574  5141   354     3     3     3     0     0     0]
 [   35   657  6400   480    34     3     0     0     0]
 [    9     2   757  1023   411    13     0     0     0]
 [   13     0     2   372  1205   243     0     0     0]
 [    2     0     0     0   155   766     0     0     0]
 [    0     0     0     0     0     6    16     0     0]
 [    0     0     0     0     0     2     0     3     0]
 [    0     0     0     0     0     0     0     0     3]]
```

准确度：0.8223

2.4.3 神经网络

混淆矩阵:

```
[[16441  1566    55     0     3     0     0     0     0]
 [ 1244  6485   392     1     0     0     0     0     0]
 [   29   499  6346   500    19     0     0     0     0]
 [   14     4   696  1110   419     9     1     0     0]
 [   16     6     2   332  1208   178     1     0     0]
 [    3     1     0     2   212   669     0     4     1]
 [    0     0     0     0     0    20     8     1     0]
 [    0     0     0     0     1     1     0     4     0]
 [    0     0     0     0     0     0     0     1     0]]
```

准确度：0.8381

神经网络我们使用了**pytorch**作为框架，其中网络的具体信息如下

> 1. *网络结构*
>
> ```
> class MyNetwork(nn.Module):
>     def __init__(self) :
>         super(MyNetwork, self).__init__()
>         self.linear_relu_stack = nn.Sequential (
>             nn.Linear(8, 20),
>             nn.SELU(),
>             nn.Linear(20, 10),
>             nn.SELU(),
>         )
>     def forward(self, x):
>         logits = self.linear_relu_stack(x)
>         return logits
> ```
>
> *网络部分，数据的输入维度为8，中间有一个维度为20的隐藏曾，输出维度为10，其中最大的维度表明网络的预测结果，激活函数选择**SELU***
>
> 2. *训练参数*
> *学习率设定为0.001，优化算法选择Adam算法，损失函数选择交叉熵损失函数，迭代次数选择为10*
>
> ```
> loss_fn = nn.CrossEntropyLoss()
> learning_rate = 1e-3
> optimizer = torch.optim.Adam(model.parameters(),
> lr=learning_rate)
>
> epochs = 10
>     for t in range(epochs):
>         print(f"Epoch {t+1}\n-----------------------------
> ---")
>         train_loop(train_data_loader, model, loss_fn,
> optimizer)
>         test_loop(test_data_loader, model, loss_fn)
>     print("Done!")
> ```

运行截图:

```
Epoch 10
-------------------------------
loss: 0.404194  [    0/154012]
loss: 0.680762  [ 6400/154012]
loss: 0.415925  [12800/154012]
loss: 0.319984  [19200/154012]
loss: 0.350248  [25600/154012]
loss: 0.326535  [32000/154012]
loss: 0.502849  [38400/154012]
loss: 0.373350  [44800/154012]
loss: 0.203996  [51200/154012]
loss: 0.331480  [57600/154012]
loss: 0.297658  [64000/154012]
loss: 0.345409  [70400/154012]
loss: 0.425146  [76800/154012]
loss: 0.331698  [83200/154012]
loss: 0.522846  [89600/154012]
loss: 0.285024  [96000/154012]
loss: 0.278727  [102400/154012]
loss: 0.356062  [108800/154012]
loss: 0.312718  [115200/154012]
loss: 0.387348  [121600/154012]
loss: 0.346462  [128000/154012]
loss: 0.345772  [134400/154012]
loss: 0.372468  [140800/154012]
loss: 0.323735  [147200/154012]
loss: 0.377576  [153600/154012]
Test Error:
 Accuracy: 83.8%, Avg loss: 0.385728
```